

Resumen de resultados

Visión Artificial · Grado en Ingeniería de Datos e IA · Universidad de León · 2025–2026

Hemos realizado cuatro pipelines, dos *deep learning* y dos clásicos, los cuales fueron evaluados sobre las mismas 22 imágenes del puesto de la fábrica de Michelin Aranda y anotaciones COCO como *ground truth*, etiquetado en **Roboflow**. Se comparan por separado la detección de bordes de corte (*cut edges*) y la detección de los QR usados para la calibración métrica.

Tabla 1 · Bordes de corte (cut edges)

Pipeline (autor)	Tipo	Det. P / R / F1	Pixel IoU	MAE (mm)	RMSE (mm)	Tiempo / img
Grounded-SAM (Pablo)	DL (GDINO+SAM)	0.906 / 0.853 / 0.879	0.7283	16.3	19.7	~6.85 s (GPU)
YOLOv9 + EfficientSAM (Jaime)	DL (YOLOv9+ESAM)	0.829 / 0.853 / 0.841	0.674	19.6	24.1	~ 3.5 s (GPU)
Clásico OpenCV (Miguel)	Clásico (Otsu+morfo.)	0.906 / 0.853 / 0.879	0.5743	24.6	30.3	~ 4.22 s (CPU)
Clásico Canny adaptativo (David)	Clásico (Canny+Otsu)	0.815 / 0.765 / 0.79	0.47	63	63.6	~ 1.5 s (CPU)

Tabla 2 · Marcadores QR (calibración distancias en mm)

Pipeline	Det. P / R / F1	Pixel IoU (Mean)
Grounded-SAM	0.954 / 0.969 / 0.961	0.651
YOLOv9 + EfficientSAM	0.984 / 0.984 / 0.984	0.865
Clásico OpenCV	0.744 / 0.953 / 0.836	0.5116
Clásico Canny adaptativo	0.833 / 0.781 / 0.807	0.5728

Recomendación

Por rendimiento global de métricas en la detección de bordes de corte, el pipeline recomendado es **Grounded-SAM**, dado que obtiene el mayor *Pixel IoU* (**0.728**), el menor *MAE* (**16.3 mm**) y el mayor *F1* de detección de bordes (**0.879**, empatado con el clásico de OpenCV y con escasa diferencia al de YOLO + EfficientSAM), y es el único que no genera falsos positivos en las cinco imágenes sin corte gracias al postprocesado aplicado con un filtro de brillo incorporado.

No obstante, en términos de velocidad de inferencia, el método recomendado es el **Clásico Canny adaptativo**, ya que tarda ~1.5 s/imagen en CPU y sin necesitar GPU ni framework de deep learning, lo que lo hace el más adecuado para un entorno de producción con hardware estándar de fábrica.

Como nota adicional, en la detección de marcadores QR, imprescindibles para la calibración métrica, el pipeline de **YOLOv9 + EfficientSAM** obtiene los mejores resultados ($F1 = 0.984$, $IoU = 0.865$).

En conclusión, en un entorno de producción donde la precisión sea crítica, **Grounded-SAM** es la opción recomendada; si el despliegue debe realizarse en hardware sin GPU, el método clásico **Canny adaptativo** ofrece una solución ligera y suficientemente robusta. Como posible mejora, un enfoque podría ser un híbrido con **YOLOv9 + EfficientSAM**, que use su detección de QRs como calibración de respaldo, para cubrir aquellos casos en los que algún pipeline no detecta los tres marcadores.